실험 제목 → 확인 의미 → 결과 → 증거 → 비용

각 항목의 상세 페이지로 이어집니다. 모의 장부와 실제 OpenAI 비용은 구분합니다.

A4 · 세션 예산 부족 - 첫 유료 단계 차단

COST_LIMIT_BLOCKED / SESSION_BUDGET_EXCEEDED.

모드: 모의 | 원문 캡처 9 | 원문 9쪽

A5 · 일일 예산 부족 - 첫 유료 단계 차단

COST_LIMIT_BLOCKED / DAILY_BUDGET_EXCEEDED.

모드: 모의 | 원문 캡처 10 | 원문 10쪽

A6 · 월 예산 부족 - 첫 유료 단계 차단

COST_LIMIT_BLOCKED / MONTHLY_BUDGET_EXCEEDED.

모드: 모의 | 원문 캡처 11 | 원문 11쪽

A7 · 두 번째 요청 예산 부족 - 생성 후 차단 개선

수정 전 답변 2회분 $0.0000306 → 수정 후 1회분 $0.0000153.

모드: 모의·별도 수정 브랜치 | 원문 캡처 12 | 원문 13쪽

V02 · 실제 OpenAI 단독 생성 - 연결·토큰 확인

보고서 기록: 입력 14 / 출력 1토큰.

모드: 실제 LLM | 원문 캡처 1 | 원문 5쪽

V02~V03 · 실제 앱 생성 - usage 정산·예약 종료

입력 59 / 출력 64토큰.

모드: 실제 LLM·모의 Guard | 원문 캡처 3 | 원문 5쪽

C1-16 · 출력 상한 16 - 비용 제한과 품질 손실

gpt-4o-mini-2024-07-18, 입력 59 / 출력 16토큰, REPORTED.

모드: 실제 LLM·모의 Guard | 원문 캡처 16 | 원문 16쪽

미검증: B1(실제 키·작은 세션 예산), C1-300(출력 300) 기록 없음. A7은 별도 수정 브랜치 결과입니다.

A4 · 세션 예산 부족 - 첫 유료 단계 차단

모의 | 확인하려는 동작과 관측 결과를 원본 캡처에 연결

실험 조건

세션 예산 $0.0003으로 정상 질문을 요청합니다.

무엇을 확인하나

세션 잔여 예산 부족을 확인합니다. 원본 캡처는 수정 전 input_guardrail 단계의 차단 기록입니다.

관측 결과

COST_LIMIT_BLOCKED / SESSION_BUDGET_EXCEEDED. 장부 0입니다.

```
PS C:\myLectureWs\legal-ai-intake-security-server> powershell.exe -NoProfile -File .\scripts\Start-LlmTestServer.ps1 -Mode Mock -SessionBud
getUsd 0.0003
Starting (Mock) on http://127.0.0.1:18090 ... (pid 21004)
READY: health=UP, mode=Mock, LLM=http://127.0.0.1:18181, maxOutputTokens=64
       budgets month/day/session = 2 / 0.5 / 0.0003 USD, requestTimeoutMs = 30000
PS C:\myLectureWs\legal-ai-intake-security-server> powershell.exe -NoProfile -File .\scripts\Invoke-AppChatOnce.ps1 -Yes -SessionId exp-a4

=== ONE app chat request (/api/ai/chat) ===
Server mode     : Mock  (guard = local mock, LLM = local mock)
Max output      : 64 tokens
Budgets m/d/s   : 2 / 0.5 / 0.0003 USD   timeout 30000 ms
Session         : exp-a4
Message (29 chars): 민사 소송을 시작하려면 어떤 서류를 준비해야 하나요?
Cost            : 0 (mock)
Retry           : none

--- cost ledger (before) (USD = reported tokens x configured price; guard stages are MOCK) ---
ai_cost_accounted_usd{} 0.0
ai_cost_actual_usd{} 0.0
ai_cost_estimated_usage_usd{} 0.0
ai_cost_reserved_usd{} 0.0
ai_cost_stage_actual_usd{stage="answer"} 0.0
ai_cost_stage_actual_usd{stage="input_guardrail"} 0.0
ai_cost_stage_actual_usd{stage="output_guardrail"} 0.0
ai_cost_stage_estimated_usage_usd{stage="answer"} 0.0
ai_cost_stage_estimated_usage_usd{stage="input_guardrail"} 0.0
ai_cost_stage_estimated_usage_usd{stage="output_guardrail"} 0.0

APP CHAT RESULT (HTTP 200)
blocked / fallback : True / True
reasonCode/detail  : COST_LIMIT_BLOCKED / SESSION_BUDGET_EXCEEDED
model              : gpt-4o-mini
usage / costSource :  /
traceId            : 30d432d9-6aa8-4508-a757-2e40df4df6bc
answer             : 현재 AI 사용 예산 한도에 도달해 다음 유료 처리 단계를 실행하지 않았습니다.
비용 절감을 위해 요청을 더 짧게 나누거나 잠시 후 다시 시도해 주세요.


--- cost ledger (after) (USD = reported tokens x configured price; guard stages are MOCK) ---
ai_cost_accounted_usd{} 0.0
ai_cost_actual_usd{} 0.0
ai_cost_blocked_total{model="gpt-4o-mini",reason="SESSION_BUDGET_EXCEEDED",stage="input_guardrail"} 1.0
ai_cost_estimated_usage_usd{} 0.0
ai_cost_reserved_usd{} 0.0
ai_cost_stage_actual_usd{stage="answer"} 0.0
ai_cost_stage_actual_usd{stage="input_guardrail"} 0.0
ai_cost_stage_actual_usd{stage="output_guardrail"} 0.0
ai_cost_stage_estimated_usage_usd{stage="answer"} 0.0
ai_cost_stage_estimated_usage_usd{stage="input_guardrail"} 0.0
ai_cost_stage_estimated_usage_usd{stage="output_guardrail"} 0.0
PS C:\myLectureWs\legal-ai-intake-security-server>
```

실험 증거: 원문 캡처 9 / 9쪽 (자르기·내용 보정 없음)

비용·OpenAI 대조

앱 장부 증가 0. 모의 공급자이며 OpenAI 과금 실측은 아닙니다.

A5 · 일일 예산 부족 - 첫 유료 단계 차단

모의 | 확인하려는 동작과 관측 결과를 원본 캡처에 연결

실험 조건

일일 예산 $0.0003으로 정상 질문을 요청합니다.

무엇을 확인하나

일일 잔여 예산 부족을 확인합니다. 원본 캡처는 수정 전 input_guardrail 단계의 차단 기록입니다.

관측 결과

COST_LIMIT_BLOCKED / DAILY_BUDGET_EXCEEDED. 장부 0입니다.

```
PS C:\myLectureWs\legal-ai-intake-security-server> powershell.exe -NoProfile -File .\scripts\Stop-LlmTestServer.ps1
Stopped LLM test server pid 21004 (mode Mock, port 18090).
PS C:\myLectureWs\legal-ai-intake-security-server> powershell.exe -NoProfile -File .\scripts\Start-LlmTestServer.ps1 -Mode Mock -DailyBudge
tUsd 0.0003
Starting (Mock) on http://127.0.0.1:18090 ... (pid 19540)
READY: health=UP, mode=Mock, LLM=http://127.0.0.1:18181, maxOutputTokens=64
       budgets month/day/session = 2 / 0.0003 / 0.12 USD, requestTimeoutMs = 30000
PS C:\myLectureWs\legal-ai-intake-security-server> powershell.exe -NoProfile -File .\scripts\Invoke-AppChatOnce.ps1 -Yes -SessionId exp-a5

=== ONE app chat request (/api/ai/chat) ===
Server mode     : Mock  (guard = local mock, LLM = local mock)
Max output      : 64 tokens
Budgets m/d/s   : 2 / 0.0003 / 0.12 USD   timeout 30000 ms
Session         : exp-a5
Message (29 chars): 민사 소송을 시작하려면 어떤 서류를 준비해야 하나요?
Cost            : 0 (mock)
Retry           : none

--- cost ledger (before) (USD = reported tokens x configured price; guard stages are MOCK) ---
ai_cost_accounted_usd{} 0.0
ai_cost_actual_usd{} 0.0
ai_cost_estimated_usage_usd{} 0.0
ai_cost_reserved_usd{} 0.0
ai_cost_stage_actual_usd{stage="answer"} 0.0
ai_cost_stage_actual_usd{stage="input_guardrail"} 0.0
ai_cost_stage_actual_usd{stage="output_guardrail"} 0.0
ai_cost_stage_estimated_usage_usd{stage="answer"} 0.0
ai_cost_stage_estimated_usage_usd{stage="input_guardrail"} 0.0
ai_cost_stage_estimated_usage_usd{stage="output_guardrail"} 0.0


APP CHAT RESULT (HTTP 200)
blocked / fallback : True / True
reasonCode/detail  : COST_LIMIT_BLOCKED / DAILY_BUDGET_EXCEEDED
model              : gpt-4o-mini
usage / costSource :  /
traceId            : 8df369bf-3ae8-4456-8a56-e04443bf03a5
answer             : 현재 AI 사용 예산 한도에 도달해 다음 유료 처리 단계를 실행하지 않았습니다.
비용 절감을 위해 요청을 더 짧게 나누거나 잠시 후 다시 시도해 주세요.


--- cost ledger (after) (USD = reported tokens x configured price; guard stages are MOCK) ---
ai_cost_accounted_usd{} 0.0
ai_cost_actual_usd{} 0.0
ai_cost_blocked_total{model="gpt-4o-mini",reason="DAILY_BUDGET_EXCEEDED",stage="input_guardrail"} 1.0
ai_cost_estimated_usage_usd{} 0.0
ai_cost_reserved_usd{} 0.0
ai_cost_stage_actual_usd{stage="answer"} 0.0
ai_cost_stage_actual_usd{stage="input_guardrail"} 0.0
ai_cost_stage_actual_usd{stage="output_guardrail"} 0.0
ai_cost_stage_estimated_usage_usd{stage="answer"} 0.0
ai_cost_stage_estimated_usage_usd{stage="input_guardrail"} 0.0
ai_cost_stage_estimated_usage_usd{stage="output_guardrail"} 0.0
PS C:\myLectureWs\legal-ai-intake-security-server>
```

실험 증거: 원문 캡처 10 / 10쪽 (자르기·내용 보정 없음)

비용·OpenAI 대조

앱 장부 증가 0. 모의 실험이며 OpenAI 과금 증감 대조 대상은 아닙니다.

A6 · 월 예산 부족 - 첫 유료 단계 차단

모의 | 확인하려는 동작과 관측 결과를 원본 캡처에 연결

실험 조건

월 예산 $0.0003으로 정상 질문을 요청합니다.

무엇을 확인하나

해당 실행본의 월 예산 제한을 확인합니다. 메모리 장부이므로 재시작을 넘어선 공급자 월 청구 한도를 증명하지 않습니다.

관측 결과

COST_LIMIT_BLOCKED / MONTHLY_BUDGET_EXCEEDED. 장부 0입니다.

```
PS C:\myLectureWs\legal-ai-intake-security-server> powershell.exe -NoProfile -File .\scripts\Stop-LlmTestServer.ps1
Stopped LLM test server pid 19540 (mode Mock, port 18090).
PS C:\myLectureWs\legal-ai-intake-security-server> powershell.exe -NoProfile -File .\scripts\Start-LlmTestServer.ps1 -Mode Mock -MonthlyBud
getUsd 0.0003
Starting (Mock) on http://127.0.0.1:18090 ... (pid 9980)
READY: health=UP, mode=Mock, LLM=http://127.0.0.1:18181, maxOutputTokens=64
       budgets month/day/session = 0.0003 / 0.5 / 0.12 USD, requestTimeoutMs = 30000
PS C:\myLectureWs\legal-ai-intake-security-server> powershell.exe -NoProfile -File .\scripts\Invoke-AppChatOnce.ps1 -Yes -SessionId exp-a6

=== ONE app chat request (/api/ai/chat) ===
Server mode     : Mock  (guard = local mock, LLM = local mock)
Max output      : 64 tokens
Budgets m/d/s   : 0.0003 / 0.5 / 0.12 USD   timeout 30000 ms
Session         : exp-a6
Message (29 chars): 민사 소송을 시작하려면 어떤 서류를 준비해야 하나요?
Cost            : 0 (mock)
Retry           : none

--- cost ledger (before) (USD = reported tokens x configured price; guard stages are MOCK) ---
ai_cost_accounted_usd{} 0.0
ai_cost_actual_usd{} 0.0
ai_cost_estimated_usage_usd{} 0.0
ai_cost_reserved_usd{} 0.0
ai_cost_stage_actual_usd{stage="answer"} 0.0
ai_cost_stage_actual_usd{stage="input_guardrail"} 0.0
ai_cost_stage_actual_usd{stage="output_guardrail"} 0.0
ai_cost_stage_estimated_usage_usd{stage="answer"} 0.0
ai_cost_stage_estimated_usage_usd{stage="input_guardrail"} 0.0
ai_cost_stage_estimated_usage_usd{stage="output_guardrail"} 0.0


APP CHAT RESULT (HTTP 200)
blocked / fallback : True / True
reasonCode/detail  : COST_LIMIT_BLOCKED / MONTHLY_BUDGET_EXCEEDED
model              : gpt-4o-mini
usage / costSource :  /
traceId            : 0e149a8b-45e1-4d59-ad1b-a21efeb1d709
answer             : 현재 AI 사용 예산 한도에 도달해 다음 유료 처리 단계를 실행하지 않았습니다.
비용 절감을 위해 요청을 더 짧게 나누거나 잠시 후 다시 시도해 주세요.


--- cost ledger (after) (USD = reported tokens x configured price; guard stages are MOCK) ---
ai_cost_accounted_usd{} 0.0
ai_cost_actual_usd{} 0.0
ai_cost_blocked_total{model="gpt-4o-mini",reason="MONTHLY_BUDGET_EXCEEDED",stage="input_guardrail"} 1.0
ai_cost_estimated_usage_usd{} 0.0
ai_cost_reserved_usd{} 0.0
ai_cost_stage_actual_usd{stage="answer"} 0.0
ai_cost_stage_actual_usd{stage="input_guardrail"} 0.0
ai_cost_stage_actual_usd{stage="output_guardrail"} 0.0
ai_cost_stage_estimated_usage_usd{stage="answer"} 0.0
ai_cost_stage_estimated_usage_usd{stage="input_guardrail"} 0.0
ai_cost_stage_estimated_usage_usd{stage="output_guardrail"} 0.0
PS C:\myLectureWs\legal-ai-intake-security-server>
```

실험 증거: 원문 캡처 11 / 11쪽 (자르기·내용 보정 없음)

비용·OpenAI 대조

앱 장부 증가 0. 원본은 모의 input_guardrail 차단 캡처입니다.

A7 · 두 번째 요청 예산 부족 - 생성 후 차단 개선

모의·별도 수정 브랜치 | 확인하려는 동작과 관측 결과를 원본 캡처에 연결

실험 조건

같은 세션 2회 요청. 수정 전 예산 $0.0004, 수정 후 $0.00085로 실험했습니다.

무엇을 확인하나

수정 전후 예산 조건이 다릅니다. 단순 비용 절감률로 비교하지 않습니다. 원본 보고서의 claude/request-budget-precheck 재실험 증거이며 현재 작업 소스 병합 증거는 아닙니다.

관측 결과

수정 전 답변 2회분 $0.0000306 → 수정 후 1회분 $0.0000153. 수정 후 두 번째 요청은 request_precheck에서 차단, reserved=0입니다.

```
PS C:\myLectureWs\legal-intake-claude-review> powershell.exe -NoProfile -File .\scripts\Invoke-AppChatOnce.ps1 -Yes -SessionId exp-a7-fix

=== ONE app chat request (/api/ai/chat) ===
Server mode     : Mock  (guard = local mock, LLM = local mock)
Max output      : 64 tokens
Budgets m/d/s   : 2 / 0.5 / 0.00085 USD   timeout 30000 ms
Session         : exp-a7-fix
Message (29 chars): 민사 소송을 시작하려면 어떤 서류를 준비해야 하나요?
Cost            : 0 (mock)
Retry           : none

--- cost ledger (before) (USD = reported tokens x configured price; guard stages are MOCK) ---
ai_cost_accounted_usd{} 1.92E-5
ai_cost_actual_usd{} 1.92E-5
ai_cost_estimated_usage_usd{} 0.0
ai_cost_reserved_usd{} 0.0
ai_cost_stage_actual_usd{stage="answer"} 1.53E-5
ai_cost_stage_actual_usd{stage="input_guardrail"} 1.95E-6
ai_cost_stage_actual_usd{stage="output_guardrail"} 1.95E-6
ai_cost_stage_estimated_usage_usd{stage="answer"} 0.0
ai_cost_stage_estimated_usage_usd{stage="input_guardrail"} 0.0
ai_cost_stage_estimated_usage_usd{stage="output_guardrail"} 0.0
ai_llm_tokens_total{model="p03-local-fixture",type="completion"} 18.0
ai_llm_tokens_total{model="p03-local-fixture",type="prompt"} 30.0


APP CHAT RESULT (HTTP 200)
blocked / fallback : True / True
reasonCode/detail  : COST_LIMIT_BLOCKED / SESSION_BUDGET_EXCEEDED
model              : gpt-4o-mini
usage / costSource :  /
traceId            : e7f56db7-3c35-45dc-99c5-bed4d26dbea4
answer             : 현재 AI 사용 예산 한도에 도달해 다음 유료 처리 단계를 실행하지 않았습니다.
비용 절감을 위해 요청을 더 짧게 나누거나 잠시 후 다시 시도해 주세요.


--- cost ledger (after) (USD = reported tokens x configured price; guard stages are MOCK) ---
ai_cost_accounted_usd{} 1.92E-5
ai_cost_actual_usd{} 1.92E-5
ai_cost_blocked_total{model="gpt-4o-mini",reason="SESSION_BUDGET_EXCEEDED",stage="request_precheck"} 1.0
ai_cost_estimated_usage_usd{} 0.0
ai_cost_reserved_usd{} 0.0
ai_cost_stage_actual_usd{stage="answer"} 1.53E-5
ai_cost_stage_actual_usd{stage="input_guardrail"} 1.95E-6
ai_cost_stage_actual_usd{stage="output_guardrail"} 1.95E-6
ai_cost_stage_estimated_usage_usd{stage="answer"} 0.0
ai_cost_stage_estimated_usage_usd{stage="input_guardrail"} 0.0
ai_cost_stage_estimated_usage_usd{stage="output_guardrail"} 0.0
ai_llm_tokens_total{model="p03-local-fixture",type="completion"} 18.0
ai_llm_tokens_total{model="p03-local-fixture",type="prompt"} 30.0
PS C:\myLectureWs\legal-intake-claude-review> powershell.exe -NoProfile -File .\scripts\Stop-LlmTestServer.ps1
```

실험 증거: 원문 캡처 12 / 13쪽 (자르기·내용 보정 없음)

비용·OpenAI 대조

모의 장부 누적 $0.00003645 → $0.0000192. 실제 OpenAI 비용 절감 실측이 아닙니다. 수정 전은 원문 텍스트 기록만 있습니다.

V02 · 실제 OpenAI 단독 생성 - 연결·토큰 확인

실제 LLM | 확인하려는 동작과 관측 결과를 원본 캡처에 연결

실험 조건

단독 스크립트로 짧은 정상 생성 1회. 응답 출력은 1토큰입니다.

무엇을 확인하나

키 인증과 실제 생성 가능 여부를 구분합니다. 이 호출은 앱 Guard 포함 전체 흐름 검증과는 별개입니다.

관측 결과

보고서 기록: 입력 14 / 출력 1토큰. 모델 생성 성공을 확인했습니다.

```
PS C:\myLectureWs\legal-ai-intake-security-server> powershell.exe -NoProfile -File .\scripts\Invoke-OpenAiSingleCall.ps1

=== ONE paid OpenAI call ===
Model           : gpt-4o-mini
Max output      : 16 tokens
Prompt          : Reply with exactly one word: OK
Worst-case cost : about $0.000025 (estimate)
Retry           : none

Type y to send exactly one request (anything else cancels): y

PAID CALL: SUCCESS
Reply           : OK
Returned model  : gpt-4o-mini-2024-07-18
Tokens in / out : 14 / 1
Estimated cost  : $0.00000270
```

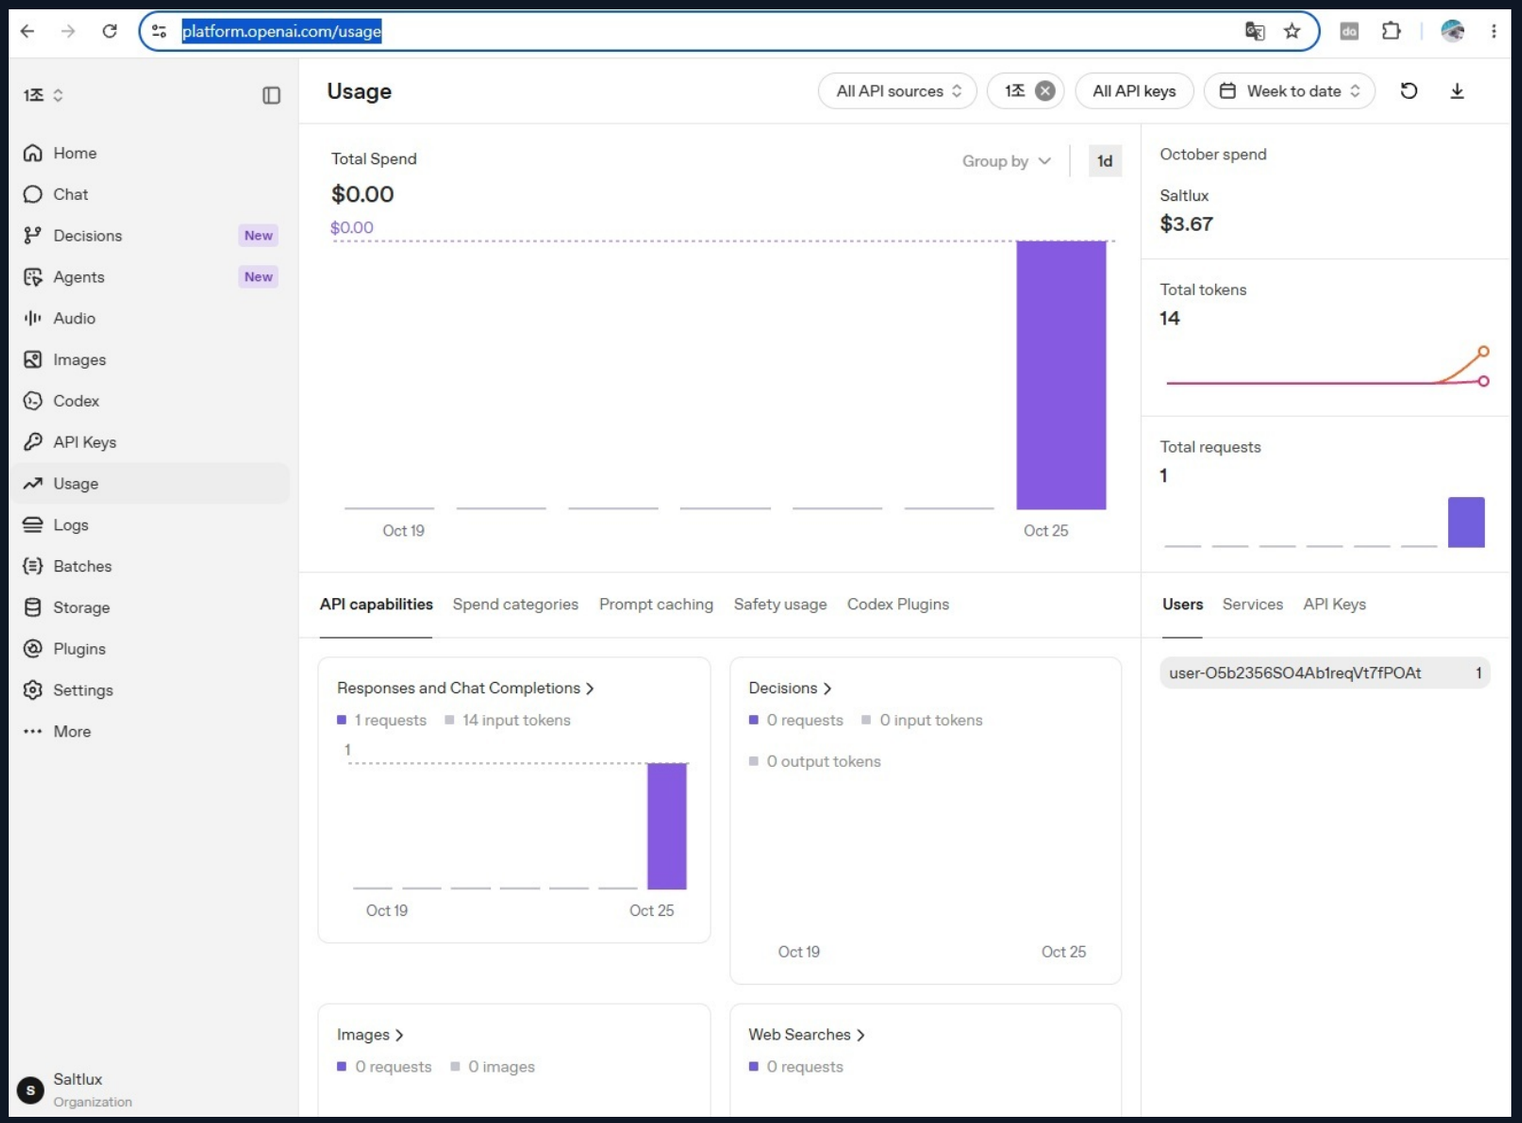
실험 증거: 원문 캡처 1 / 5쪽 (자르기·내용 보정 없음)

비용·OpenAI 대조

토큰 기준 계산 $0.0000027. OpenAI 화면 누적 요청 1회 / 입력 14토큰. Spend 표시만으로 이 소액을 직접 읽을 수는 없습니다.

V02 · OpenAI 사용량 대조

앞 페이지의 응답 토큰·비용을 공급자 사용량 화면과 연결합니다.



공급자 증거: 원문 캡처 2 / 5쪽. 사용량 화면 원본을 그대로 배치했습니다.

토큰 기준 계산 $0.0000027. OpenAI 화면 누적 요청 1회 / 입력 14토큰. Spend 표시만으로 이 소액을 직접 읽을 수는 없습니다.

V02~V03 · 실제 앱 생성 - usage 정산·예약 종료

실제 LLM·모의 Guard | 확인하려는 동작과 관측 결과를 원본 캡처에 연결

실험 조건

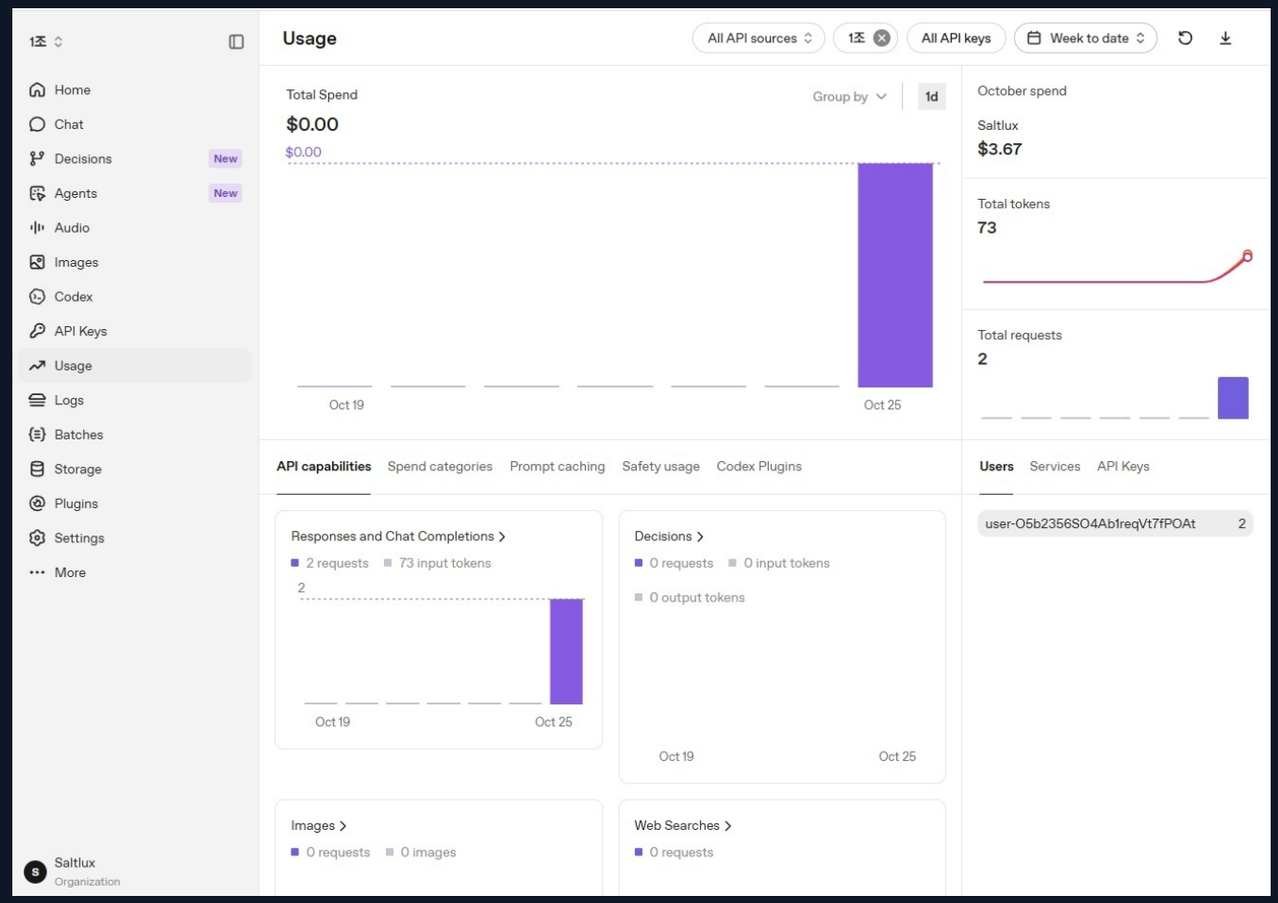
앱 경로 정상 요청 1회, 출력 상한 64토큰입니다.

무엇을 확인하나

앱 경로의 실제 응답·정산을 확인합니다. 해당 앱 호출 단독 터미널 캡처는 별도 제공되지 않아 원문 표와 공급자 누적 화면을 연결합니다.

관측 결과

입력 59 / 출력 64토큰. costSource=REPORTED, 호출 후 reserved=0으로 기록됐습니다.



실험 증거: 원문 캡처 3 / 5쪽 (자르기·내용 보정 없음)

비용·OpenAI 대조

답변 단계 계산 $0.00004725. OpenAI 누적 요청 1→2 / 입력 14→73(+59). Guard는 모의이며 실제 공급자 비용에 합산하지 않습니다.

C1-16 · 출력 상한 16 - 비용 제한과 품질 손실

실제 LLM·모의 Guard | 확인하려는 동작과 관측 결과를 원본 캡처에 연결

실험 조건

실제 앱 호출 출력 상한을 16토큰으로 설정합니다.

무엇을 확인하나

출력 상한은 비용뿐 아니라 안내 품질도 제한합니다. C1-300은 실행 기록이 없어 검증 완료로 표시하지 않습니다.

관측 결과

gpt-4o-mini-2024-07-18, 입력 59 / 출력 16토큰, REPORTED. 응답은 문장 중간에서 끊겼습니다.

```
READY: health=UP, mode=RealLlm, LLM=https://api.openai.com, maxOutputTokens=16
       budgets month/day/session = 2 / 0.5 / 0.12 USD, requestTimeoutMs = 30000
PS C:\myLectureWs\legal-ai-intake-security-server> powershell.exe -NoProfile -File .\scripts\Invoke-AppChatOnce.ps1 -SessionId exp-c1-16

=== ONE app chat request (/api/ai/chat) ===
Server mode     : RealLlm  (guard = local mock, LLM = REAL OpenAI gpt-4o-mini)
Max output      : 16 tokens
Budgets m/d/s   : 2 / 0.5 / 0.12 USD   timeout 30000 ms
Session         : exp-c1-16
Message (29 chars): 민사 소송을 시작하려면 어떤 서류를 준비해야 하나요?
Cost            : PAID if it reaches generation - about $0.0001 or less
Retry           : none

--- cost ledger (before) (USD = reported tokens x configured price; guard stages are MOCK) ---
ai_cost_accounted_usd{} 0.0
ai_cost_actual_usd{} 0.0
ai_cost_estimated_usage_usd{} 0.0
ai_cost_reserved_usd{} 0.0
ai_cost_stage_actual_usd{stage="answer"} 0.0
ai_cost_stage_actual_usd{stage="input_guardrail"} 0.0
ai_cost_stage_actual_usd{stage="output_guardrail"} 0.0
ai_cost_stage_estimated_usage_usd{stage="answer"} 0.0
ai_cost_stage_estimated_usage_usd{stage="input_guardrail"} 0.0
ai_cost_stage_estimated_usage_usd{stage="output_guardrail"} 0.0

Type y to send exactly one request (anything else cancels): y

APP CHAT RESULT (HTTP 200)
blocked / fallback : False / False
reasonCode/detail  :  /
model              : gpt-4o-mini-2024-07-18
usage / costSource : True / REPORTED
traceId            : 62c36473-d3f8-40c5-a9ed-8e6652c63d79
answer             : 민사 소송을 시작하기 위해서는 다음과 같은 일반적인 서류

--- cost ledger (after) (USD = reported tokens x configured price; guard stages are MOCK) ---
ai_cost_accounted_usd{} 2.235E-5
ai_cost_actual_usd{} 2.235E-5
ai_cost_estimated_usage_usd{} 0.0
ai_cost_reserved_usd{} 0.0
ai_cost_stage_actual_usd{stage="answer"} 1.845E-5
ai_cost_stage_actual_usd{stage="input_guardrail"} 1.95E-6
ai_cost_stage_actual_usd{stage="output_guardrail"} 1.95E-6
ai_cost_stage_estimated_usage_usd{stage="answer"} 0.0
ai_cost_stage_estimated_usage_usd{stage="input_guardrail"} 0.0
ai_cost_stage_estimated_usage_usd{stage="output_guardrail"} 0.0
ai_llm_tokens_total{model="gpt-4o-mini-2024-07-18",type="completion"} 16.0
ai_llm_tokens_total{model="gpt-4o-mini-2024-07-18",type="prompt"} 59.0
PS C:\myLectureWs\legal-ai-intake-security-server>
```

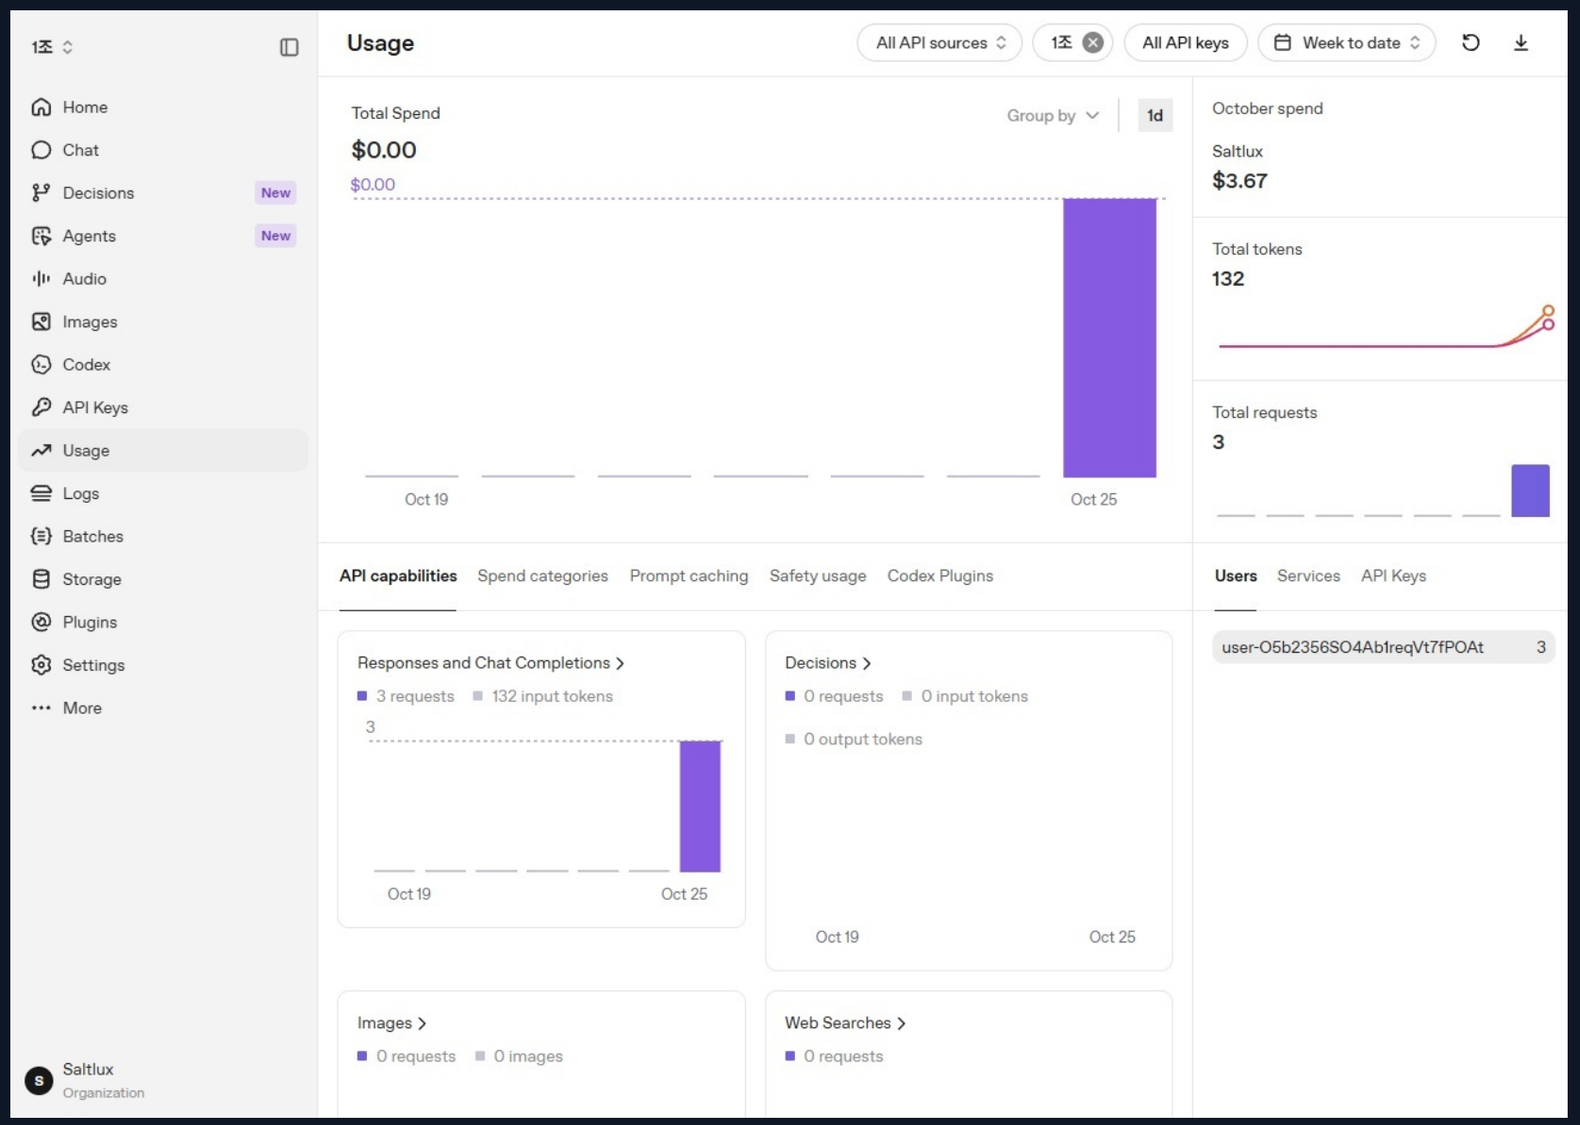
실험 증거: 원문 캡처 16 / 16쪽 (자르기·내용 보정 없음)

비용·OpenAI 대조

답변 단계 계산 $0.00001845. OpenAI 누적 요청 2→3 / 입력 73→132(+59). 확인된 3회 합계 입력132·출력81, 계산 $0.0000684; 화면 Spend는 $0.00 반올림입니다.

C1-16 · OpenAI 사용량 대조

앞 페이지의 응답 토큰·비용을 공급자 사용량 화면과 연결합니다.



공급자 증거: 원문 캡처 4 / 5쪽. 사용량 화면 원본을 그대로 배치했습니다.

답변 단계 계산 $0.00001845. OpenAI 누적 요청 2→3 / 입력 73→132(+59). 확인된 3회 합계 입력132·출력81, 계산 $0.0000684; 화면 Spend는 $0.00 반올림입니다.